DTCC 2014中国数据库技术大会

DATABASE TECHNOLOGY CONFERENCE CHINA 2014

大数据技术探索和价值发现

数据库的优化与调优：从理论到实践

网易杭研——何登成

自我简介

- 何登成
  - 网易——杭州研究院；
- **工作领域**
  - 数据库引擎/分布式数据库/分布式KV
- **技术领域**
  - 数据库/分布式/并发编程/性能优化
- **联系方式**
  - 微博：何_登成
  - 博客：何登成的技术博客

Outline

- 数据库性能优化与调优：从理论到实践
  - **理论篇**
    - 从串行到并行
    - 从畅通无阻到排队
    - 必须了解的硬件知识
  - **实践篇**
    - MySQL各版本的优化
    - MySQL使用中的调优

理论篇

- **理论篇**
  - 从串行到并行
    - 欢迎来到并行世界：Moore's Law
    - 并行世界，串行的副作用：Amdahl's law
  - 从畅通无阻到排队
    - 并发的世界，充满排队：Queueing Theory
  - 必须了解的硬件知识
    - CPU/Cache/Memory/Disk ...

欢迎来到并行世界

- 摩尔定律(Moore's Law)失效了？
  - No，只是转变了形式而已。
- Herb Sutter
  - The Free Lunch Is Over – A Fundamental Turn Toward Concurrency in Software.
- 何谓Free Lunch？
  - 通过CPU主频提升，软件能够自动提升性能的时代已经一去不复返；
  - 是时候考虑多线程/并发程序了；

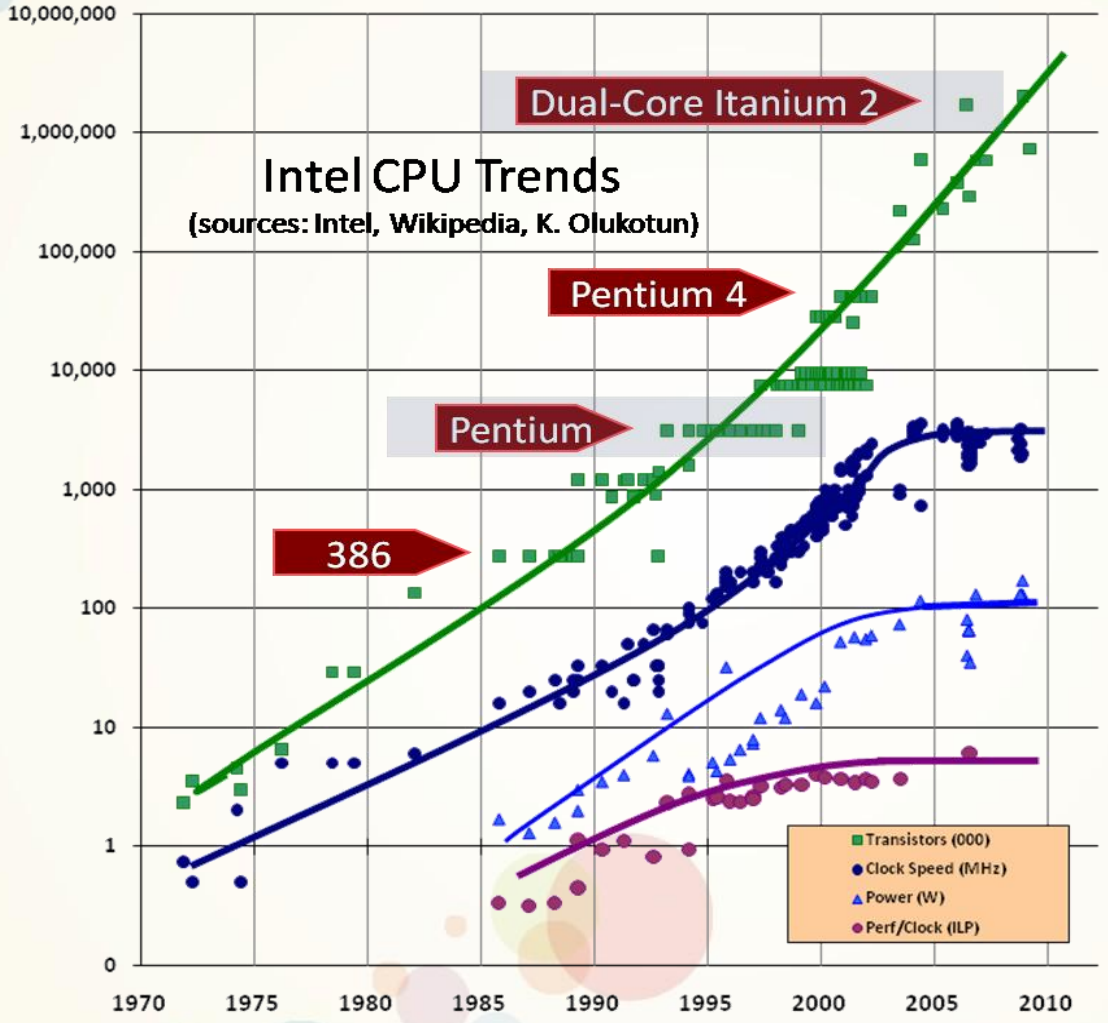

并行世界，串行的副作用

- Gene Amdahl怎么说 (Amdahl's law)？

$$S(N) = \frac{1}{(1-P) + \frac{P}{N}}$$

  - P：程序可并行执行比率
  - 1-P：串行比率
  - N：N个Processors
  - S(N)：加速比

  - 解读：程序的极限性能，最终取决于程序串行部分所占比率；
  - 尽量消除程序中的串行部分；

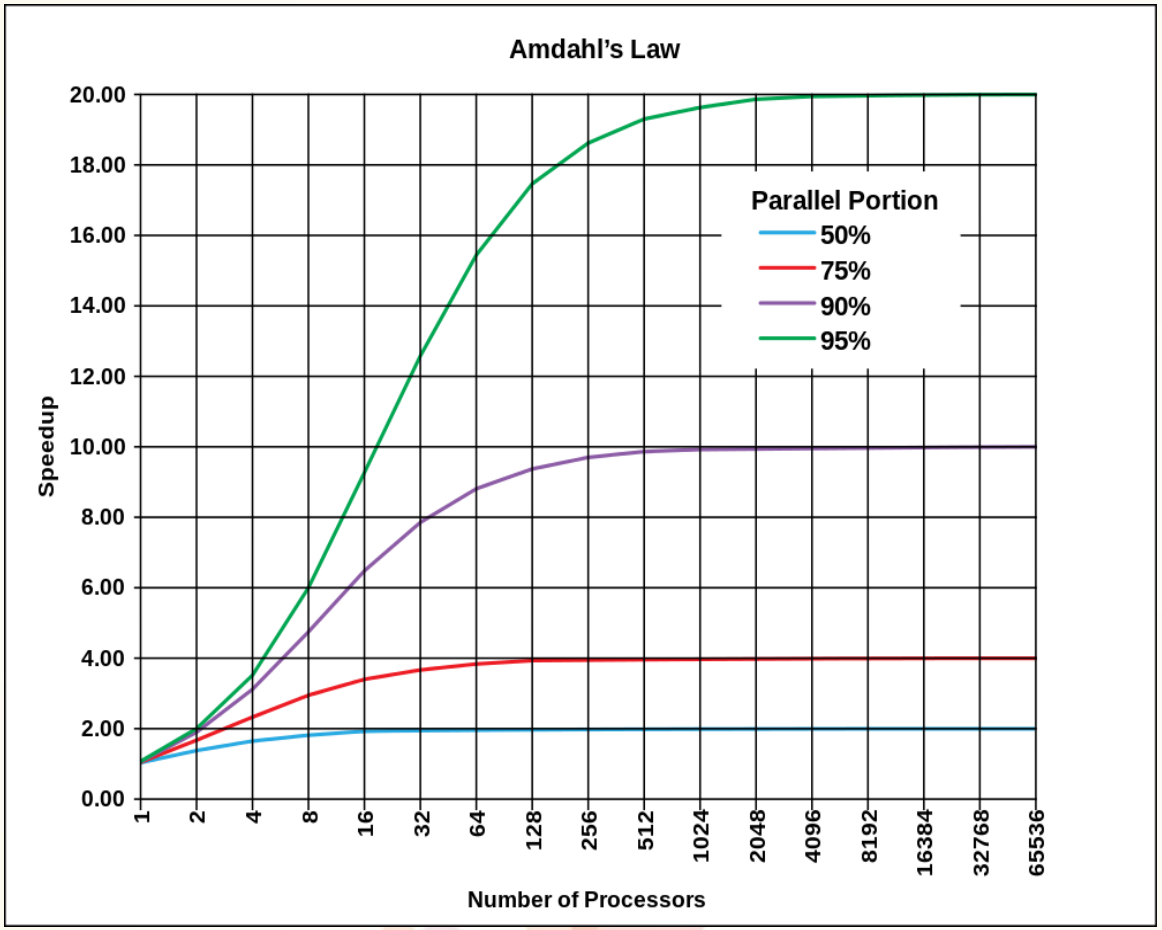

无限制的并行，您无法达到

- 现实生活中

无限制的并行，您无法达到(续)

- 硬件资源瓶颈/软件内部等待
  - CPU/Memory/Disk...
  - Mutex/Spinlock/...

- **排队论(Queueing Theory)**
  - 资源利用率；
  - 响应时间/等待时间；
  - 吞吐量；

  - 这些指标，均与性能相关；

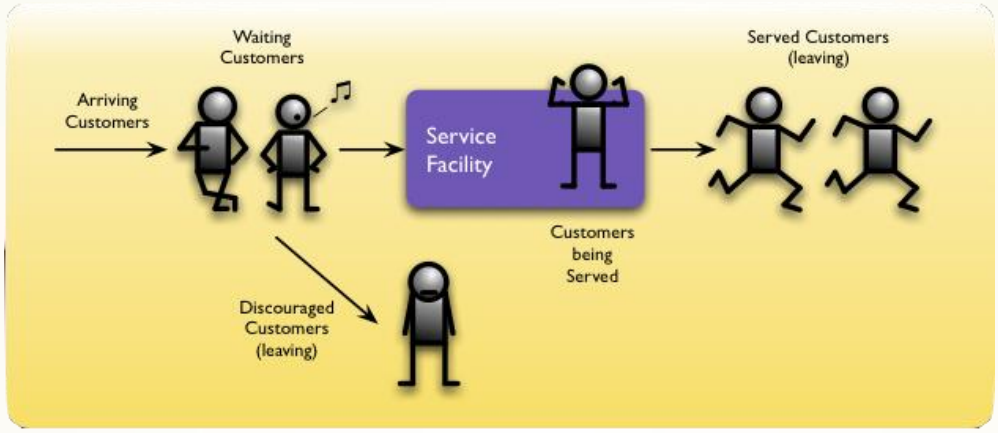

- Little's Law

$$L = \lambda W$$

  - L：平均队列长度；
  - Lambda：平均吞吐率；
  - W：平均响应时间；

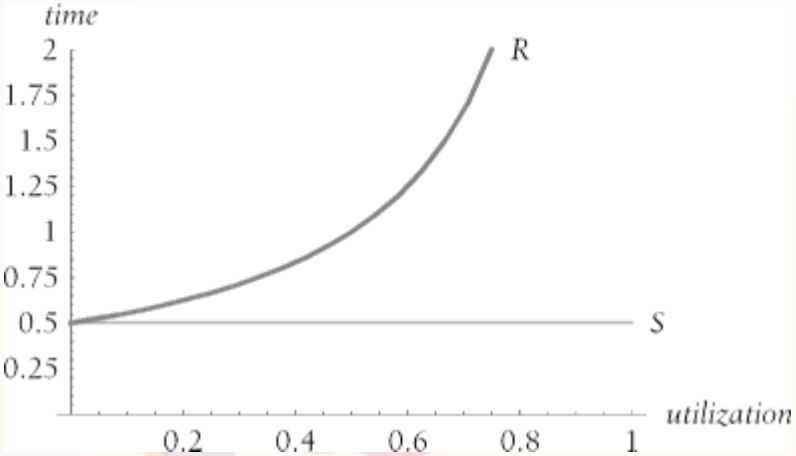

写程序，为什么需要了解硬件？

- 看看他们怎么说？
  - **Hardware and software working together in harmony.**
    - Martin Thompson
  - Know Hardware to Design Better Software.
    - 未找到出处，暂时算我说的吧☺
- 硬件与软件性能息息相关
  - 硬件各组件的Latency和Throughput；
  - 语言那些与硬件相关的特性；

当前的硬件发展到了什么阶段？

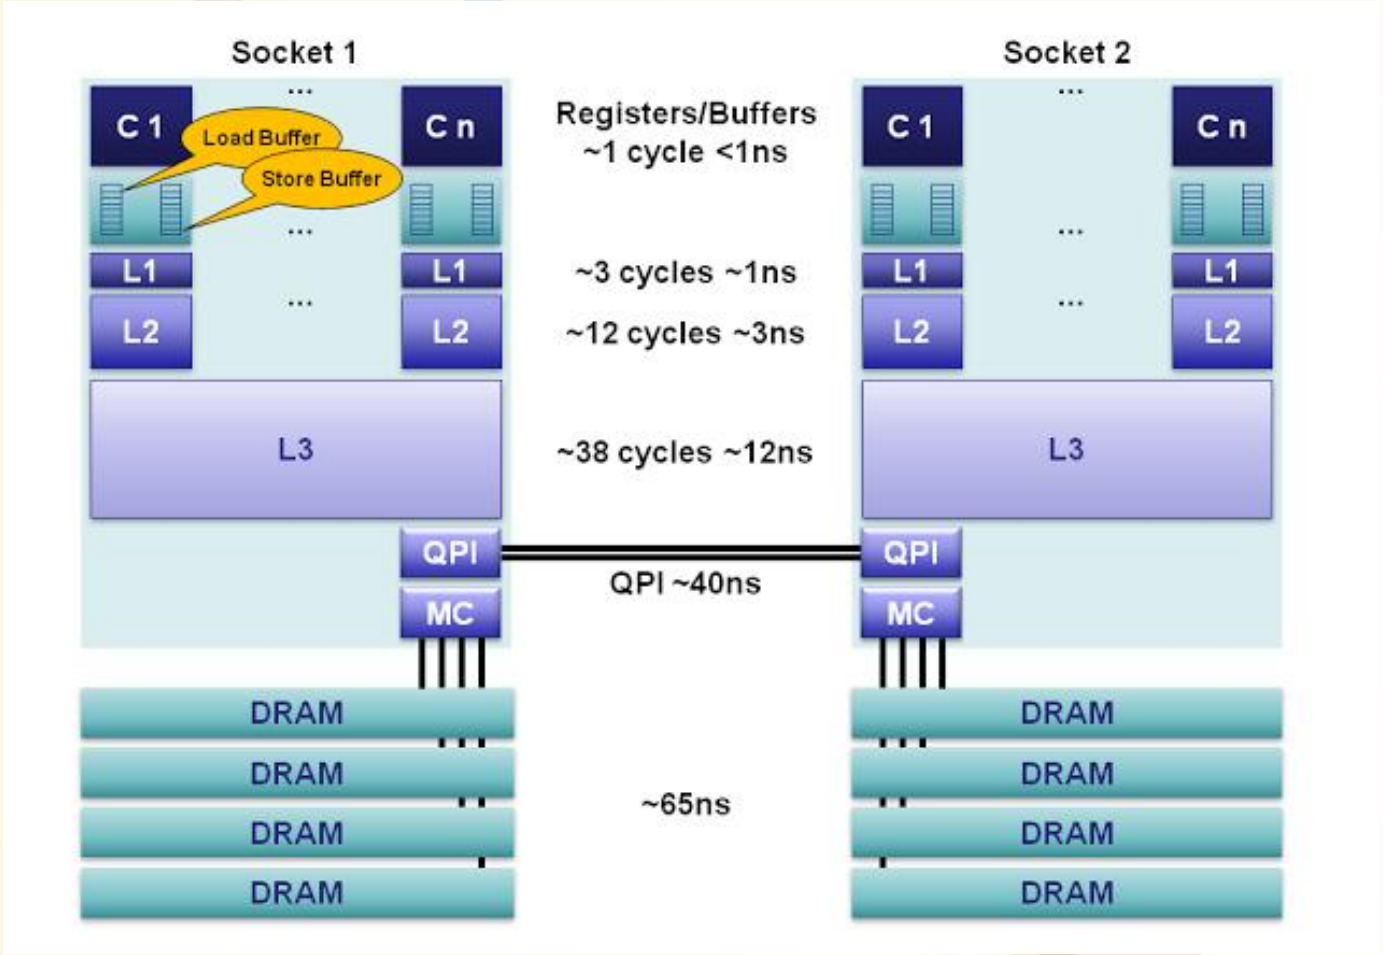

- 注：来自Martin Thompson [CPU Cache Flushing Fallacy](#) 一文；

硬件各组件Latency对比

Event	Latency	Scaled
1 CPU cycle	0.3 ns	1 s
Level 1 cache access	0.9 ns	3 s
Level 2 cache access	2.8 ns	9 s
Level 3 cache access	12.9 ns	43 s
Main memory access (DRAM, from CPU)	120 ns	6 min
Solid-state disk I/O (flash memory)	50–150 µs	2–6 days
Rotational disk I/O	1–10 ms	1–12 months
Internet: San Francisco to New York	40 ms	4 years
Internet: San Francisco to United Kingdom	81 ms	8 years
Internet: San Francisco to Australia	183 ms	19 years
TCP packet retransmit	1–3 s	105–317 years
OS virtualization system reboot	4 s	423 years
SCSI command time-out	30 s	3 millennia
Hardware (HW) virtualization system reboot	40 s	4 millennia
Physical system reboot	5 m	32 millennia

注：来自Gregg Brendan 《Systems Performance: Enterprise and the Cloud》一书；

授人以鱼不如授人以渔

- 你应该亲自测试这些硬件性能指标
  - Igor Ostrovsky——Gallery of Processor Cache Effects
    - 测试内存Latency；
    - 测试Cache Lines大小；
    - 测试L1/L2/L3 Cache大小；
    - …

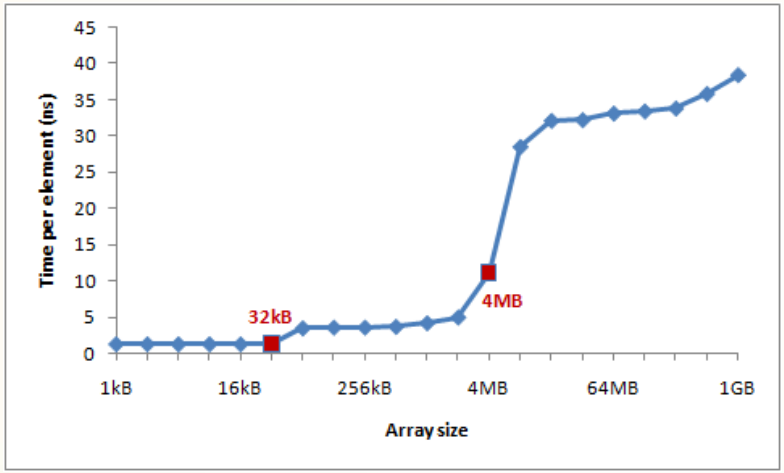

  - ccBench —— Everything You Always Wanted to Know about Synchronization but Were Afraid to Ask （SOSP’13）
    - 小工具，可以测试CPU Cache/Cache Coherence/Atomic Operations性能

理论结束，该来点实战了

- **吐槽时间**
  - 前面说了这么多，真的跟MySQL数据库的优化与调优有关系吗？你不是在忽悠吧？
  - 接下来，让我们通过实践篇，来看看前面的这些理论，在MySQL数据库中是如何得到实践的。

数据库的优化与调优：实践篇

- **实践篇**
  - MySQL各版本的优化
    - 基础优化：串行 → 并行
    - 进阶优化：减少系统中的串行点
    - 高级优化：软硬件相辅相成
  - MySQL使用中的调优
    - 资源利用率没到100%
    - 认识MySQL，构建平衡系统

基础优化-拿串行开刀(一)

- 臭名远播的prepare_commit_mutex
  - 目的：保持事务在InnoDB存储引擎与MySQL Binlog中提交顺序的一致性；
  - InnoDB Prepare：持有此Mutex
  - MySQL Binlog Commit；
  - InnoDB Commit：释放此Mutex
  - 事务串行化提交；

- MySQL Group Commit
  - Oracle MySQL Group Commit
    - Starting with MySQL 5.6
  - MariaDB Group Commit
    - Starting with MariaDB 5.3
  - How?

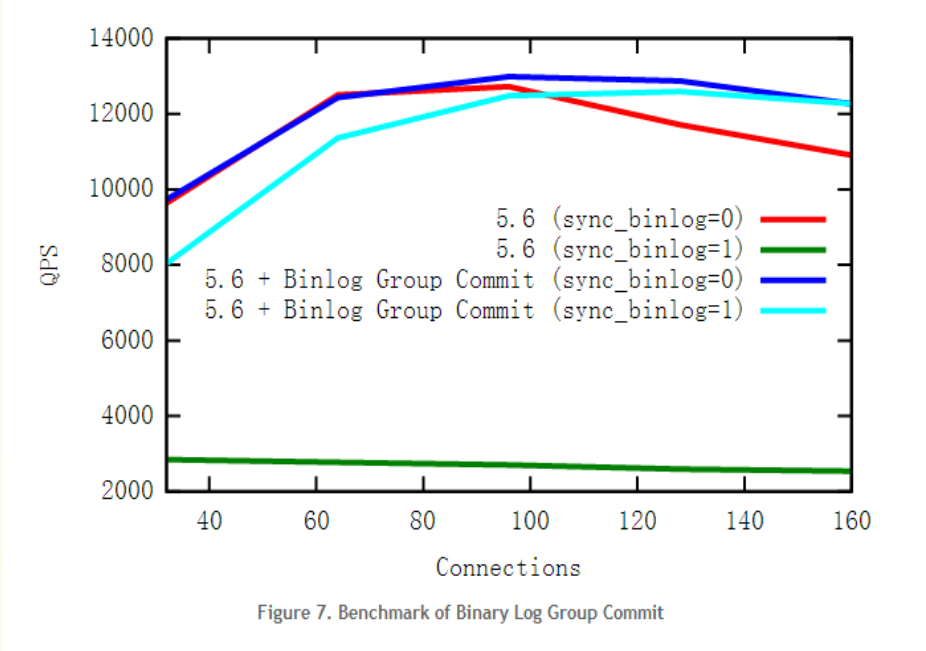

Figure 7. Benchmark of Binary Log Group Commit

基础优化-拿串行开刀(二)

- 你的Slave延迟了多久？
  - MySQL Replication
    - 基于Binlog的复制
  - 两个线程
    - I/O Thread：　　负责与Master通讯，接收Binlog
    - SQL Thread：　　负责Binlog在Slave的回放，单线程

- Parallel Slave Replication
  - Oracle MySQL
    - Starting with MySQL 5.7.2
  - MariaDB Implementation
    - Starting with MariaDB 10.0.5
  - 效果(见右图)

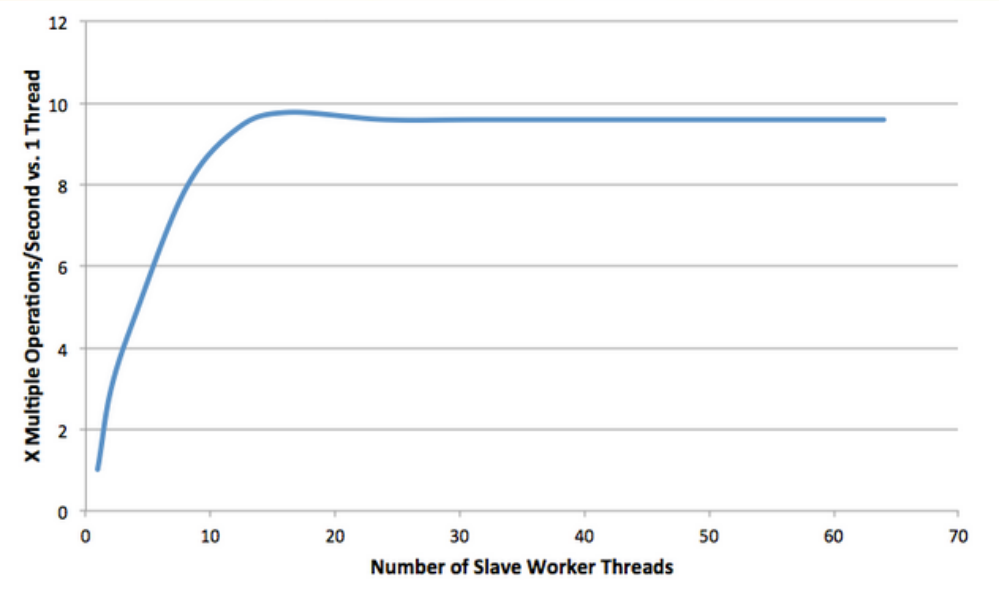

进阶优化-减少系统串行点(一)

- kernel_mutex
  - InnoDB引擎内部有很多共享资源，如：内存分配，日志系统，事务与锁表，ReadView...
  - 早期InnoDB版本，所有的这些共享资源，
  - kernel_mutex，针对MySQL/InnoDB系统来

- 一字真言
  - 拆！！！
  - Kernel mutex removed
  - 事务 & ReadView： trx_sys_t::lock
  - 锁表： lock_sys_t::mutex
  - ...

进阶优化-减少系统串行点(二)

- Index Tree Lock
  - InnoDB每一个Index，有一把RWLock(读写锁)；
  - 读/写，加S锁；
  - 索引页面分裂/合并，加X锁；
  - 索引页面分裂时，整个索引树不可访问 ☹

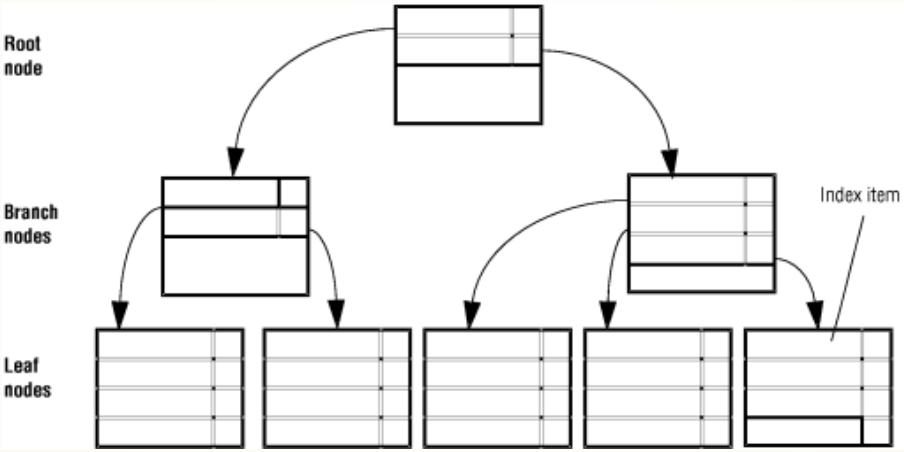

- 二字真言
  - **算法！！**
  - C. Mohan, Aries/IM
  - SMO操作，只跟SMO本身冲突，不会堵塞用户的读写；

高级优化-软硬件相辅相成(一)

- 高级CPU指令
  - SIMD SSE 4
    - Single-Instruction-Multiple-Data
- 合适的应用场景
  - InnoDB页面计算Checksum；
  - 硬件指令加速；

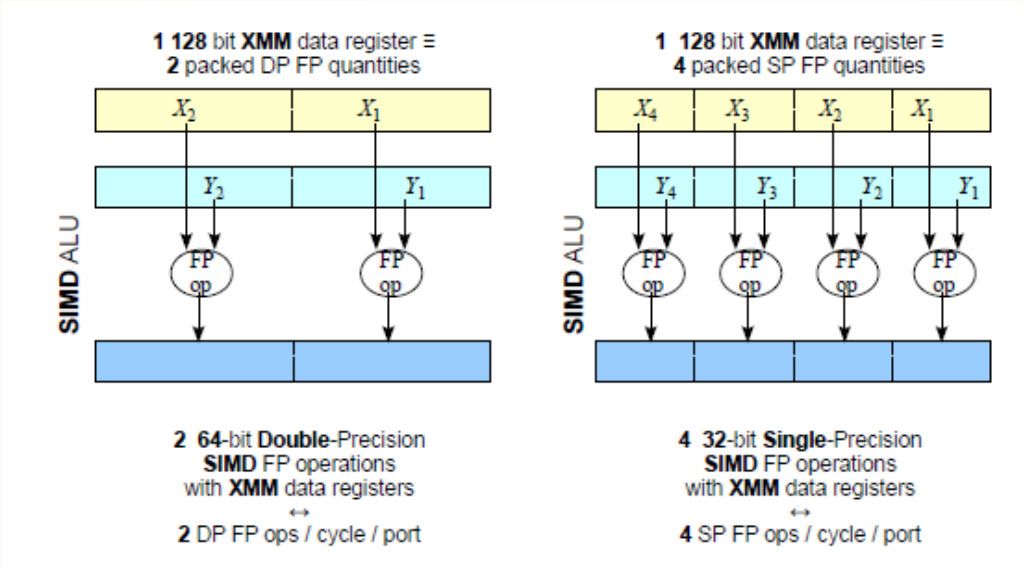

高级优化-软硬件相辅相成(二)

- Cache Coherence & False Sharing
  - Cache Coherence
    - 多线程并发读写同一内存；
  - False Sharing
    - 64 Bytes Cache Line

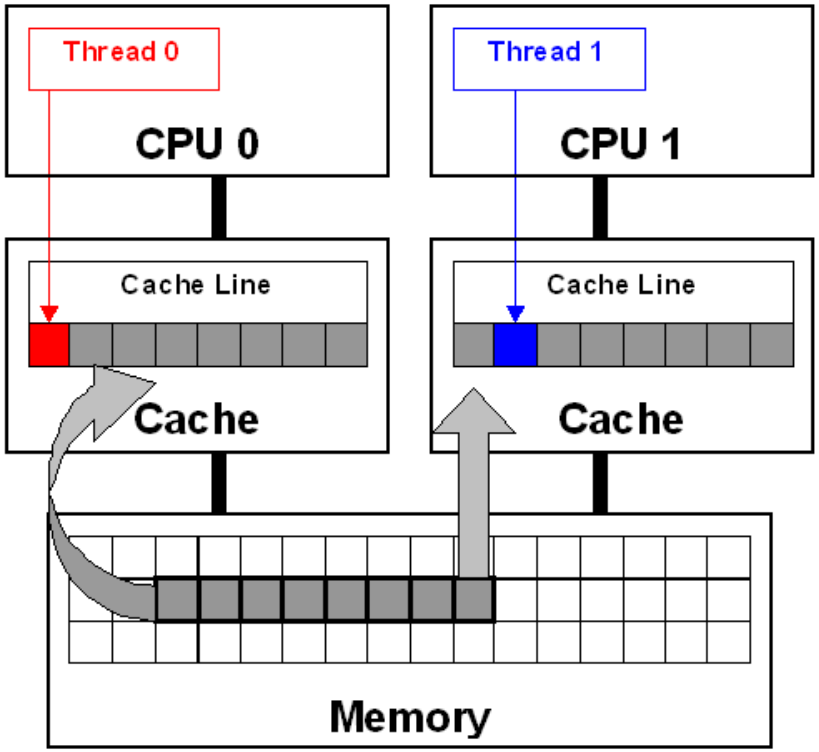

- G5 Patch
  - 问题起因
    - srv_n_rows_read++
  - Per-Thread Counter
    - 减少Cache Coherence
  - Counter Padding
    - 消除False Sharing
    - ib_counter_t::m_counter[(N + 1) * (CACHE_LINE_SIZE) / sizeof(Type)]

高级优化-软硬件相辅相成(三)

- Compile Optimization
  - CPU执行
  - L1 ICache高速指令缓存

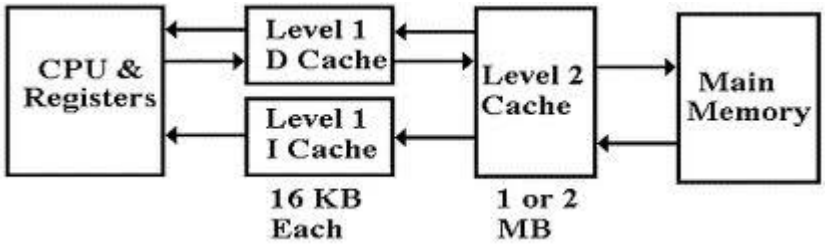

- 减少ICache Miss
  - Perf：定位Cache Miss
  - PGO：优化编译
  - 优化效果
    - ICache Miss：　10% to 8%
    - Performance：　44%提升

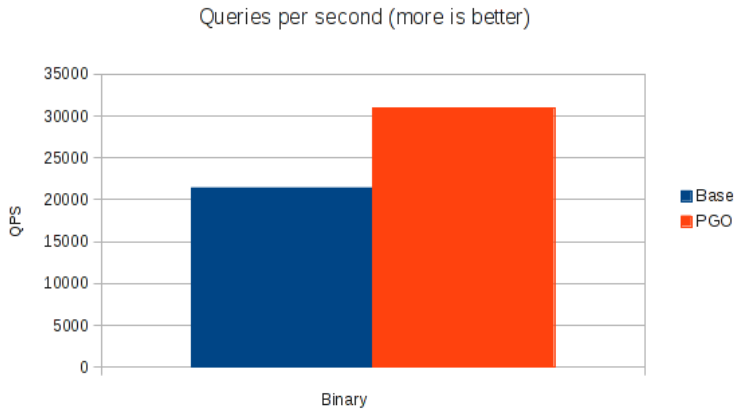

MySQL调优-关注资源利用率

- 一个数据库系统，其硬件资源(CPU、Disk、SSD...)利用率是不是越高，说明系统调优的越好？
- 用户关注
  - **响应时间(Latency)**
- 老板关注
  - **资源有没有浪费？**
- 调优关注
  - 保证用户响应时间的基础上，最大限度提高资源利用率；
  - Finding The Knee

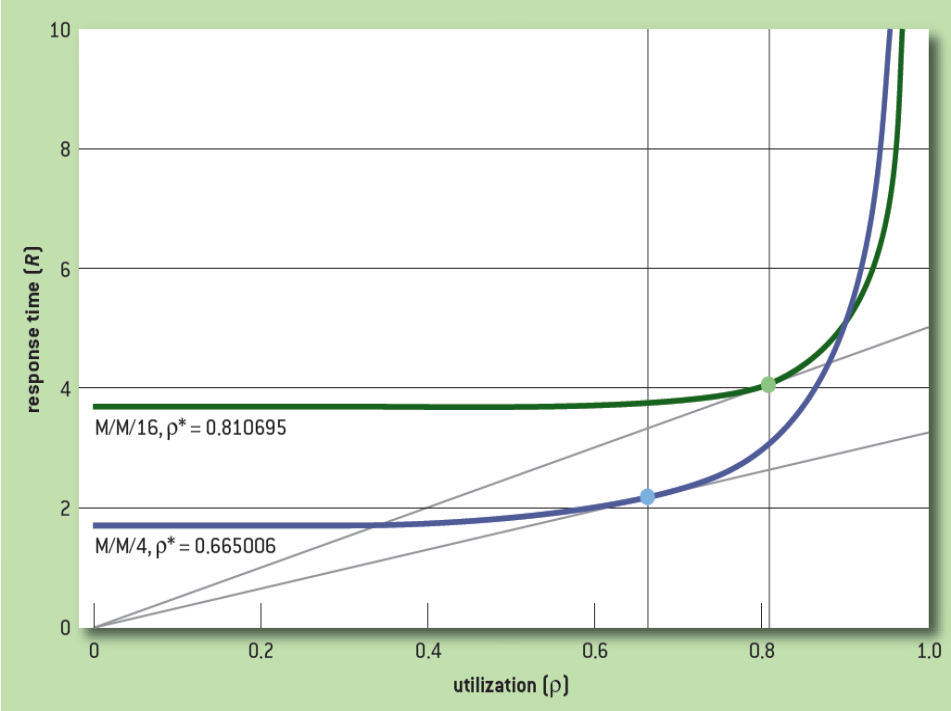

MySQL调优-认识MySQL，构建平衡系统

- 认识MySQL
  - MySQL能支持多少并发？消耗多少CPU？
  - 指导采购不同的硬件配件；

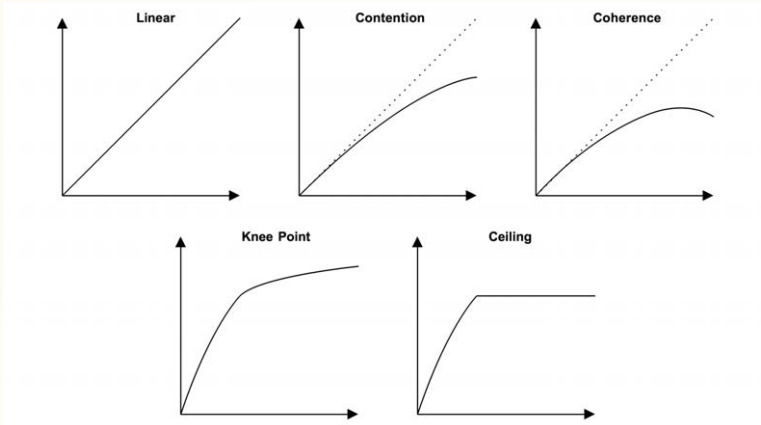

- 构建平衡系统(Balanced Systems)
  - Balanced Systems
    - 硬件有着基本相同的资源利用率吗？
    - 每个硬件的利用率都处于拐点吗？
  - 指导数据库服务器选型；
  - 合适的CPU、磁盘、网络、SSD组合；

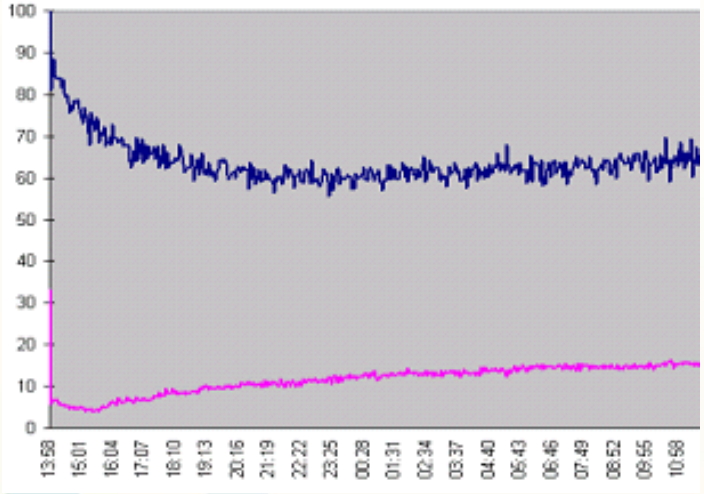

MySQL调优-终极调优

- 面向程序员的数据库访问性能优化法则

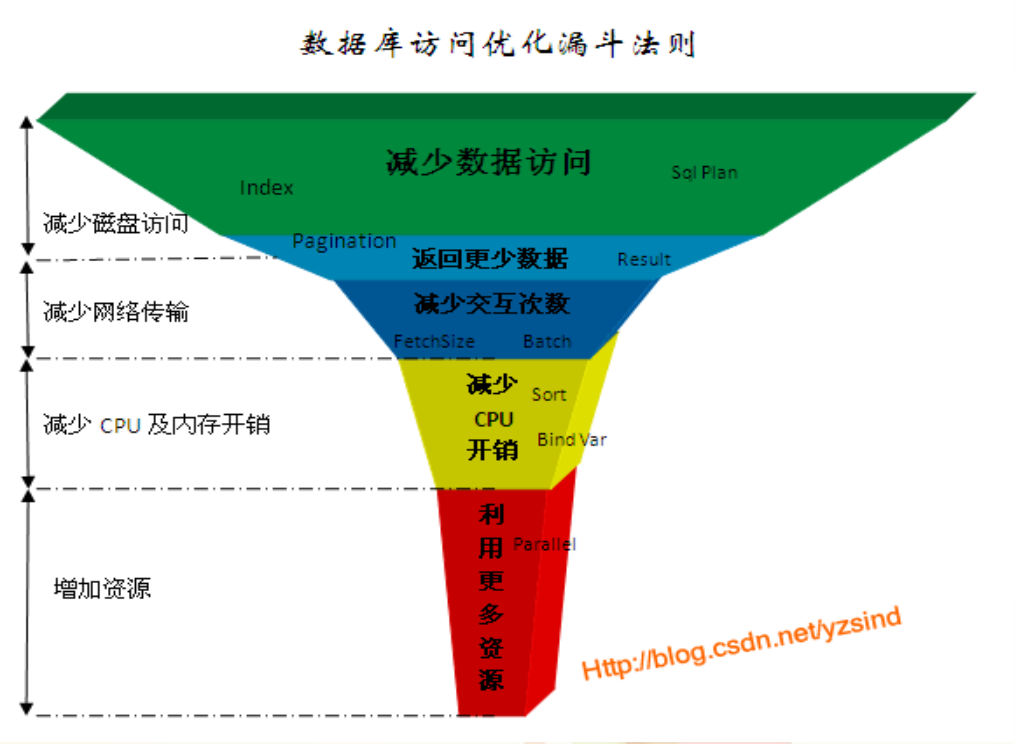

- 写在最后的一句话
  - 数据库层面做再大的性能优化，都抵不上应用层的优化。同样是MySQL，既可以用来支撑Google/FaceBook/Taobao应用，也可能连你的个人网站都撑不住；

Q&A

THANKS